

MAÎTRISEZ LES LLM — GPT, Claude, Grok

> Promesse mesurable : à la fin, vous savez choisir le bon modèle pour chaque tâche, rédiger un prompt qui donne le bon résultat du premier coup, et automatiser vos tâches répétitives avec les API — vous gagnez 5 heures par semaine sur votre travail documentaire.

>

> Format : pack PDF, 7 modules, ~4 h de lecture + exercices.

> Cible : professionnels (commerciaux, rédacteurs, assistants, techniciens) qui utilisent déjà ChatGPT « comme Google » et veulent passer au niveau supérieur.

> Prérequis : savoir utiliser un navigateur et copier-coller. Zéro code requis (l'API est optionnelle, module 7).

> Durée : 4 h (2 h de théorie + 2 h d'exercices), à faire en 1 semaine.

Module 1 — Qu'est-ce qu'un LLM, vraiment (et pourquoi ça change vos prompts)

Leçon

Un LLM (Large Language Model) est un modèle de prédiction de texte statistique entraîné sur des centaines de milliards de tokens. Il ne « sait » pas : il calcule, à chaque mot, la probabilité du prochain mot le plus plausible. C'est la raison de ses deux forces et de son défaut majeur :

- Force 1 : il a absorbé une partie immense de la connaissance publique (jusqu'à sa date de coupe). Il est excellent pour reformuler, résumer, traduire, structurer.
- Force 2 : il comprend l'intention derrière vos mots, pas seulement les mots. D'où l'importance du contexte.
- Défaut : il hallucine quand il ne sait pas. Il préfère inventer une réponse plausible plutôt que dire « je ne sais pas ». Parfois, la date de coupe le rend obsolète.

Conséquences pratiques :

1. Ne demandez jamais un fait précis sans vérification (chiffres, dates, citations, articles de loi). Demandez d'abord, vérifiez ensuite.
2. Donnez le contexte complet : rôle, objectif, public, format, contraintes. Un LLM sans contexte est un stagiaire sans brief.
3. Le modèle détermine la qualité de base, mais le prompt détermine 80 % du résultat. Un bon prompt sur un modèle moyen bat un mauvais prompt sur le meilleur modèle.

Les 4 grands modèles, quand les utiliser

| Modèle | Forces | À éviter | Coût d'accès |

|---|---|---|---|

| GPT-4o / GPT-4.1 (OpenAI) | Raisonnement solide, écosystème API le plus complet, outils (fonctions, vision) | Tâches triviales (cher) | 20 \$/mois (ChatGPT Plus) ; API payante |

| Claude (Anthropic) | Écriture longue de qualité (rapports, code, analyses), respect des instructions longues, fenêtre de contexte énorme (200k-1M) | Tâches très courtes et répétitives | 20 \$/mois (Claude Pro) ; API payante |

| Grok (xAI) | Actualité récente (données temps réel via X), ton direct, bon marché en API | Rédaction longue nuancée | Inclus X Premium ; API bon marché |

| Modèles open source (Llama, Mistral, Qwen via Ollama) | Gratuit, données privées restent chez vous, hors-ligne | Tâches complexes, français moyen selon les modèles | Gratuit (serveur local) |

Règle du pro : le meilleur modèle n'existe pas — il existe le bon modèle pour la tâche. Longue rédaction → Claude. Tâches courtes et structurées → GPT. Actualité → Grok. Confidentialité → local.

Exemple réel

Mauvais prompt : « Résume ce texte. »

Bon prompt : « Tu es un assistant commercial. Résume ce compte-rendu de réunion en 5 puces, en français, en gardant les décisions et les responsables. Si une décision est ambiguë, écris "(à clarifier)". »

Le deuxième donne un résultat exploitable directement, le premier donne un pavé générique.

Exercice pratique

1. Prenez un texte professionnel que vous avez sous la main (email long, rapport, article).
2. Faites-le résumer par GPT, Claude et Grok avec le même prompt « pauvre ».
3. Faites-le résumer avec le même prompt « riche » (rôle + objectif + format + contrainte).
4. Comparez les 4 résultats : notez la différence entre les modèles et entre les prompts. Écrivez 3 lignes sur ce que vous retenez.

Module 2 — La conversation : votre premier outil de travail

Leçon

Un LLM en chat n'est pas une calculatrice, c'est un collaborateur avec mémoire de session. Utilisez cette mémoire :

1. Ouvrez une session par projet (pas un méli-mélo). La mémoire de la session, c'est le contexte gratuit.
2. Corrigez plutôt que reformulez : au lieu de réécrire tout le prompt, dites « non, garde le ton mais raccourcis les phrases de moitié ». Le modèle itère sur la session.
3. Demandez des questions avant la production : « Avant d'écrire, pose-moi les 3 questions qui changeraient tout. » Un pro pose 30 secondes de questions, gagne 20 minutes de correction.
4. Exigez des sources ou un signal d'incertitude : « Si tu n'es pas sûr d'un chiffre, écris [VÉRIFIER] à la place. »

Les 7 rôles qui marchent

Démarrez vos prompts par un rôle précis. Voici les 7 rôles les plus rentables au quotidien :

1. Le réviseur : « Corrige ce texte : orthographe, grammaire, style. Propose 2 versions : une formelle, une directe. »
2. Le traducteur : « Traduis en anglais commercial, pas littéral. »
3. L'analyste : « Quels sont les 3 risques de ce contrat/projet ? Justifie. »
4. Le formateur : « Explique-moi X comme à un débutant, avec une analogie. »
5. Le contradicteur : « Trouve les 5 faiblesses de mon argumentation. »
6. Le rédacteur de brief : « À partir de cette idée, écris un brief complet de 10 lignes pour un prestataire. »
7. Le synthétiseur : « Transforme cette discussion en compte-rendu avec décisions, actions et responsables. »

Exemple réel

Un technicien doit préparer un point d'avancement : il colle la conversation complète du support dans la session, puis demande : « Tu es mon assistant. Résume cette conversation client en : contexte, problème, actions faites, prochaine étape. Ajoute une section "risque si on ne fait rien". » Résultat : un compte-rendu prêt en 2 minutes au lieu de 30.

Exercice pratique

Prenez votre dernière réunion (ou un échange client) et produisez : un compte-rendu avec le rôle 7, puis une version « email au client » de 8 lignes maximum. Mesurez le temps gagné.

Module 3 — Le prompt en 6 briques (framework C.O.N.T.E.X.T.)

Leçon

Un prompt professionnel se construit comme un brief. Mémorisez les 6 briques :

| Lettre | Brique | Question à se poser | Exemple |

|---|---|---|---|

| C | Contexte | De quoi parle-t-on ? | « Nous sommes une TPE de 6 personnes » |

| O | Objectif | Quel est le livrable ? | « un argumentaire de vente » |

| N | Nature | Quel format ? | « un document d'une page, 6 sections » |

| T | Ton | Quel style ? | « direct, sans jargon, tutoiement » |

| E | Exemple | Un modèle de sortie ? | « comme cet email que je joins » |

| X | eXigences | Contraintes, interdits ? | « sans promesse de résultat garanti, max 400 mots » |

Le E (exemple) est la brique la plus puissante : montrer un exemple vaut mieux que décrire. Le X est la plus négligée : sans interdits, le modèle part dans son sens.

Le framework avancé : le prompt « en trois temps »

Pour les tâches importantes, ne demandez pas la production directe :

1. Phase 1 — Compréhension : « Voici le sujet. Reformule ce que tu as compris et pose-moi tes questions. »
2. Phase 2 — Plan : « Voici les réponses. Propose un plan de [livrable] avec le contenu de chaque section en une ligne. »
3. Phase 3 — Production : « Le plan est validé. Rédige maintenant. »

Cela coûte 3 messages au lieu d'un, mais élimine 90 % des résultats à jeter.

Exemple réel

Prompt complet : « C. Je suis consultant indépendant, je vends des formations IA aux PME. O. Rédige un email de relance pour un prospect qui a reçu mon devis il y a 10 jours sans réponse. N. Email de 120 mots max. T. Courtois, direct, sans agressivité. E. [collez un email que vous avez déjà envoyé et qui a marché]. X. Pas de rabais, une seule relance mentionnée, CTA clair : un créneau de 15 min. »

Exercice pratique

1. Écrivez un prompt C.O.N.T.E.X.T. complet pour une tâche réelle de votre semaine (email, rapport, analyse).
2. Faites la version « trois temps ».
3. Comparez les résultats avec votre prompt habituel. Conservez le gagnant dans un fichier mes-prompts.md que vous allez construire tout au long de la formation.

Module 4 — Récupérer de l'information : téléverser des fichiers

Leçon

Les modèles modernes (GPT-4o, Claude, Grok) acceptent des fichiers joints : PDF, images, tableurs, code. C'est votre raccourci n°1 : ne recopiez plus jamais un document, téléversez-le.

Ce que ça débloque :

- PDF : résumé, extraction des points clés, recherche de clauses, comparaison de deux contrats.
- Tableurs (CSV/XLSX) : analyse de données, détection d'anomalies, préparation de rapports.
- Images : lecture de captures d'écran, OCR, description d'un schéma, lecture d'un graphique.
- Code : explication, débogage, traduction d'un langage à un autre.

Limites à connaître : la date de coupe (le modèle ne connaît pas le futur), la taille (certains modèles limitent le volume), et la confidentialité (les données envoyées à un service cloud ne sont pas « chez vous » — vérifiez les CGU pour des données sensibles, et utilisez un modèle local dans ce cas).

La technique du « double questionnement »

Sur un document long, ne demandez jamais tout d'un coup. Deux passes :

1. Passe panoramique : « Résume ce document en 10 puces. Quelles sont les 3 idées principales ? »
2. Passe chirurgicale : « Dans la section 3, quels sont exactement les montants et les échéances ? »

La passe 2 est beaucoup plus fiable quand elle s'appuie sur la passe 1 (le modèle sait déjà où chercher).

Exemple réel

Un gérant reçoit un contrat de 40 pages d'un fournisseur. Il téléverse le PDF : « Résume en 10 puces, puis liste toutes les clauses qui m'engagent financièrement ou dans la durée, avec le numéro de page de chacune. » En 5 minutes, il a la carte des risques — et les pages à montrer à son avocat.

Exercice pratique

1. Prenez un PDF professionnel que vous avez (devis, contrat, rapport) et téléversez-le.
2. Faites la passe panoramique puis la passe chirurgicale.
3. Vérifiez une information précise de la passe 2 en ouvrant le PDF à la page indiquée. Notez dans mes-prompts.md le prompt qui a donné la meilleure précision.

Module 5 — Générer : emails, posts, rapports, traductions

Leçon

La génération est le cœur de l'usage pro. Les 4 grands types de production, avec leur recette :

1. L'email (la recette la plus rentable)

Toujours fournir : destinataire, relation (prospect/client/collègue), objectif, ton, longueur, CTA. Et toujours relire et personnaliser : un email 100 % généré se sent à 100 mètres.

2. Le post LinkedIn / X

Fournir : sujet, promesse, longueur (X : < 280 caractères ; LinkedIn : 150-250 mots), ton, CTA, et 1-3 « hooks » au choix. Le hook est la première ligne : c'est elle qui décide du scroll ou du clic.

3. Le rapport / compte-rendu

Technique du « document à trous » : demandez le squelette (sections + questions), remplissez les données vous-même, puis demandez la rédaction complète. Vous gardez le contrôle des faits, le modèle gagne le temps de rédaction.

4. La traduction

Précisez toujours « traduction adaptée, pas littérale » et le registre (commercial, technique, familial). Les modèles traduisent mieux que 90 % des humains sur les textes professionnels — et c'est gratuit.

Les 5 erreurs qui font un résultat « robot »

1. Prompt trop court sans contexte → texte générique.
2. Pas d'exemple → style par défaut du modèle.
3. Pas d'interdit → des phrases vides (« dans le monde d'aujourd'hui »).
4. Demander « parfait » sans itération → on jette au lieu de corriger.
5. Copier-coller sans relire → fautes, erreurs factuelles, ton faux.

Règle d'or : le LLM produit une première version. Le pro passe 30 % du temps à demander, 70 % à diriger les corrections.

Exemple réel

Prompt : « Écris un email de 100 mots à un client qui a acheté ma formation il y a 3 mois : je propose un rappel gratuit de 20 min pour l'aider à appliquer. Ton : utile, pas commercial. CTA : 3 créneaux proposés. Interdit : mot "relance", emojis. » Résultat : un email d'entretien de client, pas de spam.

Exercice pratique

Générez : (1) un email de suivi de devis, (2) un post LinkedIn sur votre métier avec 3 hooks au choix, (3) la traduction anglaise de votre offre. Corrigez chaque version en 2 itérations. Conservez les 3 prompts gagnants.

Module 6 — Les pièges : hallucination, biais, données sensibles

Leçon

Un utilisateur avancé connaît les limites mieux que les capacités. Les 5 pièges :

1. L'hallucination — le modèle invente avec aplomb (chiffres, citations, articles de loi, références). Antidote : demandez des sources, exigez « [VÉRIFIER] » quand incertain, vérifiez les faits critiques vous-même. Ne demandez JAMAIS à un LLM un montant, une date limite ou une clause juridique sans vérification externe.
2. La date de coupe — le modèle ne connaît pas le présent. Pour de l'actualité : Grok (temps réel), ou activez la recherche web si l'outil le propose. Vérifiez toujours ce qui date de moins de 2 ans.
3. Les biais — le modèle reproduit les biais de ses données d'entraînement (stéréotypes, angles morts culturels). Antidote : demandez explicitement plusieurs points de vue : « Donne aussi la vision opposée. »
4. La confidentialité — ne mettez jamais dans un chat public ou une API sans accord : données clients identifiables, mots de passe, documents stratégiques non publiés, secrets industriels. Pour le sensible : modèle local (Ollama), ou un abonnement avec clause de non-utilisation des données (Claude Pro / API avec « zero data retention »).
5. La surconfiance — le résultat est fluide donc il paraît vrai. Antidote : traitez chaque sortie comme un brouillon d'un stagiaire brillant mais faillible.

La checklist anti-hallucination (à coller dans vos prompts sensibles)

> « Tu n'es pas autorisé à inventer. Pour chaque chiffre, citation, date ou référence : écris [VÉRIFIER] si tu n'es pas certain à 95 %. À la fin, liste les 3 informations les plus risquées à vérifier. »

Exemple réel

Un étudiant demande à ChatGPT un résumé de la loi qui s'applique à son projet, avec les articles cités. Le modèle produit un texte impeccable... avec deux articles inexistantes. Le réflexe pro : croiser avec le site officiel (legifrance.gouv.fr) avant toute utilisation. Le LLM a gagné 30 minutes de rédaction, l'humain garde la responsabilité du contenu.

Exercice pratique

1. Posez au modèle une question factuelle précise (date, chiffre, loi) sans lui demander de vérifier. Puis la même question avec la checklist anti-hallucination.
2. Comparez : où sont les [VÉRIFIER] ?
3. Classez les données de votre activité en 3 catégories : « OK à envoyer », « OK avec précautions », « jamais » (ex. : mots de passe, données clients).

Module 7 — Passer à l'API : automatiser vos tâches répétitives (optionnel, sans code requis)

Leçon

L'interface chat est manuelle. L'API transforme le LLM en service automatique : votre boîte mail, votre CRM ou un script peut appeler le modèle à la demande. C'est ce qui se cache derrière tous les « agents » et automatisations modernes.

Le principe : une requête HTTP avec votre clé, vous recevez la réponse du modèle. Les fournisseurs (OpenAI, Anthropic, xAI) offrent tous la même logique : model, messages (rôle + contenu), temperature (créativité 0-2, défaut 1). Le prix se compte en tokens (≈ 750 mots).

Votre premier appel (OpenAI, 5 minutes) :

1. Créez un compte sur platform.openai.com, ajoutez un crédit (5-10 \$ suffisent pour tester des semaines).
2. Générez une clé API (Settings → API keys).
3. Copiez ce script dans un fichier test-api.py (Python 3, installer avec pip install openai) :

```
from openai import OpenAI
client = OpenAI(api_key="VOTRE_CLE")

reponse = client.chat.completions.create(
    model="gpt-4o-mini",
    messages=[
        {"role": "system", "content": "Tu résumes des emails en 3 puces, en français."},
        {"role": "user", "content": "Résume : [COLLEZ VOTRE EMAIL ICI]"}
    ]
)
```

```
],
    temperature=0.3
)
print(reponse.choices[0].message.content)
```

4. Lancez `python3 test-api.py`. Si le terminal affiche le résumé : félicitations, vous venez d'automatiser une tâche. Ce code, branché sur votre boîte mail (via n8n, IFTTT, Zapier ou Make), tourne sans vous.

Sécurité de la clé : une clé API, c'est un mot de passe. Ne la partagez jamais, ne la collez jamais dans un chat public, ne la mettez jamais dans un fichier envoyé. Stockez-la dans un gestionnaire de secrets (Keychain sur Mac, gestionnaire de mots de passe) ou un fichier `.env` jamais commité.

Exemple réel

Un indépendant reçoit 30 emails de devis par semaine. Il branche n8n : chaque email entrant → appel API → résumé en 3 puces → le résumé arrive dans sa messagerie. Coût : ~0,01 \$ par email, soit 0,30 \$/semaine. Gain : 1 h 30 de lecture. Le retour sur investissement d'une API se compte en centimes.

Exercice pratique

1. Créez votre compte OpenAI (ou Anthropic/xAI), ajoutez un crédit minimal, générez une clé.
2. Exécutez le script ci-dessus sur un vrai email.
3. Identifiez une tâche répétitive de votre semaine (résumé, traduction, reformulation) et notez comment vous la brancheriez sur une API. C'est votre premier projet d'automatisation.

Checklist de fin de formation

- ☐ Je sais différencier les 4 grands modèles et choisir selon la tâche
- ☐ J'utilise les rôles et la mémoire de session dans mes chats
- ☐ Je construis mes prompts avec les 6 briques C.O.N.T.E.X.T.
- ☐ Je fais la méthode « trois temps » pour les tâches importantes
- ☐ Je téléverse des fichiers et fais les deux passes (panoramique/chirurgicale)
- ☐ J'ai généré et corrigé : 1 email, 1 post LinkedIn, 1 traduction
- ☐ J'ai ma checklist anti-hallucination dans mes prompts sensibles
- ☐ J'ai classé mes données en 3 catégories de confidentialité
- ☐ Mon fichier mes-prompts.md contient au moins 5 prompts gagnants réutilisables
- ☐ J'ai fait mon premier appel API (même minimal) : `python3 test-api.py` fonctionne

Résultat mesurable : une tâche documentaire qui vous prenait 1 h vous prend désormais 10-15 min, et vous avez une bibliothèque de prompts réutilisables.

Prix conseillés

| Formule | Contenu | Prix |

|---|---|---|

| Pack PDF | Les 7 modules + checklist | 27 € |

| Pack complet | Pack PDF + mes-prompts.md (50 prompts pro prêts à copier) + 10 templates d'emails + 1 h de Q&A en visio | 47 € |

Note de vente : le pack PDF seul justifie 15 € minimum ; à 27 €, il se positionne en « outil de travail » (pas un cours), ce qui justifie le prix face à la masse de contenu gratuit. Le pack complet à 47 € porte le vrai chiffre d'affaires : chaque vente complète = presque 2× le pack simple, pour un coût marginal nul.